

TP 2

Traitement des données avec Pandas

Cours : Nettoyage, indexation, interrogation et agrégation
Public : futurs ingénieurs | Durée indicative : 3h


Positionnement du TP

Ce TP est centré sur Pandas : nettoyage, indexation, interrogation, agrégation et jointure de données. Il prépare les étudiants à travailler sur des fichiers métiers imparfaits, comme dans un contexte d'entreprise.

1. Objectifs pédagogiques

- Manipuler un DataFrame Pandas de manière structurée.
- Détecter et traiter les valeurs manquantes.
- Créer des indicateurs métiers à partir de colonnes existantes.
- Interroger un DataFrame avec des conditions simples et combinées.
- Utiliser groupby, sort_values, merge et pivot_table pour produire une analyse synthétique.

Pipeline de traitement



2. Contexte métier

Une entreprise commerciale veut analyser ses ventes mensuelles afin d'identifier les produits les plus rentables, les régions les plus performantes et les anomalies de saisie. Le fichier fourni contient des valeurs manquantes et doit être préparé avant toute analyse fiable.

3. Préparation de l'environnement

Code 1 - Bibliothèques

```
pip install pandas matplotlib openpyxl

import pandas as pd
import matplotlib.pyplot as plt
```

4. Jeux de données

Créer deux fichiers CSV : ventes.csv et regions.csv. Le second fichier servira à introduire la jointure de données.

Fichier CSV - ventes.csv

```
Date,Produit,Categorie,Region,Quantite,Prix_Unitaire
2024-01-05,PC Portable,Informatique,Casablanca,4,8500
2024-01-07,Souris,Accessoire,Rabat,20,120
2024-01-12,Clavier,Accessoire,Casablanca,15,250
2024-01-15,Ecran,Informatique,Tanger,6,1800
2024-01-18,PC Portable,Informatique,Rabat,,8500
2024-01-20,Imprimante,Informatique,Casablanca,3,2200
2024-01-25,Souris,Accessoire,Tanger,30,120
2024-01-28,Clavier,Accessoire,Rabat,10,
2024-02-02,Ecran,Informatique,Casablanca,5,1800
2024-02-05,Imprimante,Informatique,Tanger,2,2200
```

Fichier CSV - regions.csv

```
Region,Responsable,Objectif_CA
Casablanca,Amina,50000
Rabat,Yassine,35000
Tanger,Hajar,25000
```

5. Travail demandé

Exercice 1 - Chargement et inspection

Code 2 - Lecture et diagnostic

```
df = pd.read_csv("ventes.csv")
regions = pd.read_csv("regions.csv")

print(df.head())
print(df.info())
print(df.isnull().sum())
```

- Quelles colonnes contiennent des valeurs manquantes ?
- Combien de valeurs manquantes existe-t-il au total ?
- Pourquoi les valeurs manquantes peuvent-elles fausser une analyse ?
- Quelle différence entre info(), describe() et isnull().sum() ?

Exercice 2 - Nettoyage des valeurs manquantes

Code 3 - Traitement des valeurs manquantes

```
# Remplacer Quantite par la moyenne des quantités disponibles
df["Quantite"] = df["Quantite"].fillna(df["Quantite"].mean())

# Remplacer Prix_Unitaire par la médiane pour limiter l'effet des valeurs extrêmes
df["Prix_Unitaire"] = df["Prix_Unitaire"].fillna(df["Prix_Unitaire"].median())

print(df.isnull().sum())
```

Méthode	Quand l'utiliser ?	Limite
Suppression	Peu de lignes manquantes et données non critiques	Perte d'information
Moyenne	Variable numérique avec distribution stable	Sensible aux valeurs extrêmes
Médiane	Variable numérique avec valeurs extrêmes possibles	Moins précise si la distribution est normale
Valeur métier	Règle connue par l'entreprise	Nécessite validation experte

- Pourquoi la médiane peut-elle être préférable à la moyenne ?
- Cette stratégie de remplacement est-elle toujours correcte ? Justifier.
- Quelle autre stratégie pourrait être utilisée dans un contexte réel ?

Exercice 3 - Indexation et interrogation

Code 4 - Indexation et filtres

```
# Conversion de la date et utilisation comme index temporaire
df["Date"] = pd.to_datetime(df["Date"])
df_date = df.set_index("Date")
print(df_date.loc["2024-01"])

# Sélection de colonnes
```

```
print(df[["Produit", "Region", "Quantite"]])

# Filtre simple
print(df[df["Region"] == "Casablanca"])

# Filtre combiné
filtre = (df["Region"] == "Casablanca") & (df["Categorie"] == "Informatique")
print(df[filtre])
```

- Quel est l'intérêt de convertir la colonne Date en type datetime ?
- Quelle est la différence entre loc et une sélection conditionnelle ?
- Combien de ventes Informatique ont été réalisées à Casablanca ?

Exercice 4 - Création d'indicateurs

Code 5 - Indicateurs métiers

```
df["Chiffre_Affaires"] = df["Quantite"] * df["Prix_Unitaire"]
df["Mois"] = df["Date"].dt.to_period("M")

print(df[["Date", "Produit", "Region", "Chiffre_Affaires", "Mois"]])
```

- Quel produit génère le chiffre d'affaires le plus élevé sur une ligne ?
- Quel est le chiffre d'affaires total de l'entreprise ?
- Pourquoi créer une variable Mois ?

Exercice 5 - Groupby et tri des résultats

Code 6 - Agrégation

```
ca_region = df.groupby("Region")["Chiffre_Affaires"].sum().sort_values(ascending=False)
ca_produit = df.groupby("Produit")["Chiffre_Affaires"].sum().sort_values(ascending=False)
ca_categorie = df.groupby("Categorie")["Chiffre_Affaires"].sum()

print(ca_region)
print(ca_produit)
print(ca_categorie)
```

Code 7 - Visualisation

```
ca_region.plot(kind="bar", figsize=(7, 4))
plt.title("Chiffre d'affaires par région")
plt.ylabel("Chiffre d'affaires")
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()
```

- Quelle région est la plus performante ?
- Quel produit est le plus rentable ?
- La catégorie Informatique domine-t-elle toujours ? Justifier par les chiffres.

Exercice 6 - Jointure de données avec merge

Code 8 - Merge et taux de réalisation

```
df_complet = pd.merge(df, regions, on="Region", how="left")
print(df_complet.head())

ca_objectif = df_complet.groupby(["Region", "Responsable",
    "Objectif_CA"])[["Chiffre_Affaires"].sum().reset_index()
ca_objectif["Taux_Realisation"] = ca_objectif["Chiffre_Affaires"] /
    ca_objectif["Objectif_CA"] * 100
print(ca_objectif)
```

- Quelle est la clé de jointure utilisée ?
- Que signifie how="left" ?
- Quelle région réalise le meilleur taux de réalisation ?
- Quelle recommandation peut-on proposer au responsable de la région la moins performante ?

Exercice 7 - Tableau croisé dynamique

Code 9 - Pivot table

```
pivot = pd.pivot_table(
    df,
    values="Chiffre_Affaires",
    index="Region",
    columns="Categorie",
    aggfunc="sum",
    fill_value=0
)
print(pivot)
```

- Quelle région vend le plus de produits Accessoire ?
- Quelle catégorie domine à Rabat ?
- Quelle information le tableau croisé rend-il plus lisible qu'un simple tableau brut ?

6. Travail à rendre

- Un Notebook Python propre, commenté et exécuté.
- Les deux fichiers CSV.
- Les sorties principales : groupby, merge, pivot_table.
- Au moins deux graphiques lisibles.
- Une conclusion de 10 lignes comprenant : région performante, produit rentable, qualité des données et recommandations.

7. Grille d'évaluation indicative

Critère	Barème
Chargement des données et inspection initiale	3 pts
Traitement des valeurs manquantes avec justification	4 pts
Indexation, filtres et interrogation du DataFrame	4 pts
Création et interprétation du chiffre d'affaires	3 pts
Groupby, merge, pivot_table et visualisation	4 pts
Conclusion métier claire	2 pts

8. Références indicatives

- Marc Buffat, Université Lyon 1 - Chapitre Pandas et Big Data.
- Initiation à Python pour le traitement de données - GitBook.